Vadim Prokhorov

contact@vadim-prokhorov.eu | linkedin.com/in/vadim-prokhorov-58b755298 | github.com/Valikpp | vadim-prokhorov.eu | Île-de-France

PROFIL

Recherche un stage d'été, de juillet à août 2027, en data science, machine learning ou data engineering. Élève ingénieur en 1re année à **Télécom Paris** (Institut Polytechnique de Paris), admis par le concours GEI-UNIV (20 places par cette voie), après une licence d'informatique mineure mathématiques à **Sorbonne Université** (**2e sur 57** en L2). **Quatre expériences data**, dont un modèle et un service mis en production chez DOCENT. Je travaille sur le versant mathématique de la data science : tests d'hypothèses, conception de métriques d'évaluation, modélisation bayésienne. Et je mets en production ce que je conçois (Python, FastAPI, PostgreSQL, Docker, AWS).

FORMATION

Cycle ingénieur, 1re année Télécom Paris, Institut Polytechnique de Paris, Palaiseau — 2026 - 2029

Admis par le concours GEI-UNIV, très sélectif : 20 places à Télécom Paris par cette voie. Diplôme prévu en 2029. Cours de 1re année : probabilités, analyse fonctionnelle et de Fourier, communications numériques et théorie de l'information, logique.

Licence Informatique, mineure Mathématiques Sorbonne Université, Faculté des Sciences et Ingénierie, Paris — 2023 - 2026

Moyennes annuelles : L1 **17.49/20** | L2 **15.92/20, 2e sur 57** | L3 **17.53/20**. Sciences des données 95.75/100 (**1er sur 117**) | Réseaux 100/100 (**1er sur 316**) | Algorithmique II (3e sur 318) | Structures de données (4e sur 392) | Algorithmique I (6e sur 496) | Mathématiques pour les sciences 1 et 2 : 96.6/100 et 98/100 (36e sur 2227).

EXPÉRIENCES PROFESSIONNELLES

DOCENT — Mars - Août 2026

Stagiaire Data Scientist

Plateforme d'analyse et de prédiction des tendances culturelles | mi-temps puis plein temps | équipe anglophone

- **Méthode de segmentation retenue en production**, sélectionnée parmi 15 configurations d'algorithmes évaluées sur 8 tests indépendants, grâce à un banc de comparaison reproductible rejouant l'étude entière en 2 minutes (scikit-learn, scipy, UMAP). Segmentation déterministe, macro-F1 **0.776**.
- **Métrique sur mesure :** score de recouvrement opposant un plafond analytique aux partitions dégénérées qui remportaient les métriques standards.
- **Optimisation arrêtée sur preuve statistique :** trois tests indépendants (Hopkins entre 0.54 et 0.60, co-association entre méthodes, accord inter-annotateurs) ont établi l'absence de structure de groupes naturelle. Deux experts s'accordaient moins entre eux (ARI 0.170) que le modèle retenu avec eux (ARI 0.189) : le plafond venait de la référence humaine.
- **Piège de mesure identifié avant publication :** à partition identique, la silhouette passe de 0.018 dans l'espace d'origine à 0.326 après projection UMAP. Décision : regrouper dans l'espace d'origine, réserver les projections à la visualisation.
- **Moteur de rapprochement marque - artistes** porté à **0.768** de précision au premier résultat contre 0.140 pour un tirage aléatoire, en comparant 18 méthodes sur trois protocoles (hold-out stratifié, cas réels, bootstrap) ; variante bayésienne (Bernoulli-Beta) pour les usages exigeant une probabilité calibrée.
- **Pipeline d'annotation par LLM industrialisé :** trois workflows no-code (n8n) remplacés par un service Python en production (FastAPI, PostgreSQL, ~60 endpoints REST, Docker, AWS), avec suivi du coût par exécution et reprise après échec partiel. Plateforme exploitée sur ~1 000 artistes, conçue pour plusieurs dizaines de milliers (PostgreSQL indexé, conteneurs workers ajustés à la charge, traitements asynchrones).

Agency 1301 — Automne 2025

Data Scientist (freelance)

Détection de republication non autorisée de photographies (droit d'auteur)

- **Taux de détection rendu interprétable :** statuts d'échec typés et distinction entre score non calculable et score réellement nul ; une absence de résultat n'est plus confondue avec une panne technique, ce qui supprime un biais silencieux dans les statistiques.
- **Seuil de décision réexaminable :** persistance de tous les candidats, retenus comme rejetés (100 à 200 par photo) ; recalibrer ne demande plus de relancer des recherches de plusieurs heures par lot. Seuil, version et horodatage gelés à chaque exécution ; vérité terrain annotée sur 6 niveaux.

- Base PostgreSQL complète dimensionnée pour leurs volumes, ouverte aux utilisateurs non techniques via NocoDB avec gestion des droits.

Prana France

Mai - Août 2025

Stagiaire Data Analyst

PME industrielle, ventilation double-flux et décentralisée

- Tableaux de bord Power BI sur les ventes, l'activité commerciale et la génération de leads, à partir de données préparées en SQL.
- Assistant de support client par **RAG** développé en Python sur les embeddings de la documentation produit, déployé sur AWS.

SAS Datafoncier

Juin - Août 2024

Stagiaire Data Scientist

Start-up, analyse du marché immobilier

- Prédiction du marché immobilier par régression (prix, surface, tendances) : réglage des hyperparamètres, validation croisée, rééquilibrage des classes, données manquantes ; extraction de features par **ResNet** pour estimer l'état des biens.

COMPÉTENCES TECHNIQUES

Mathématiques & statistique: Tests d'hypothèses | bootstrap | métriques d'accord (ARI, alpha de Cronbach) | Hopkins | inférence bayésienne (Bernoulli-Beta, a priori conjugués, shrinkage, calibration) | ACP, analyse procustéenne | conception de métriques et correction du hasard

Machine learning: scikit-learn | PyTorch | TensorFlow | scipy | classification & régression | clustering (KMeans, Ward, HDBSCAN) | réduction de dimension (ACP, UMAP, t-SNE, MDS) | protocoles d'évaluation

IA générative & LLM: RAG | embeddings | bases vectorielles | ingénierie des prompts | systèmes agentiques | sentence-transformers | CLIP | n8n

Données & backend: Python | C | C++ | SQL | PostgreSQL (schémas, indexation, montée en charge) | FastAPI | Pandas | NumPy | NocoDB | Power BI

Infrastructure: Docker | AWS (EC2, RDS, S3) | traitements asynchrones et parallélisés | Git | Linux | pytest | Claude Code, Cursor, MCP

Langues: Russe (langue maternelle) | Français (C1) | Anglais (B2, TOEFL iBT 87/120, langue de travail chez DOCENT) | Permis B

Centres d'intérêt: Tennis (bon niveau) | échecs | programmation compétitive | Kaggle