Vadim Prokhorov

contact@vadim-prokhorov.eu | linkedin.com/in/vadim-prokhorov-58b755298 | github.com/Valikpp | vadim-prokhorov.eu |
Île-de-France

PROFIL

Recherche un stage d'été, de juillet à août 2027, en data science, machine learning ou data engineering. Élève ingénieur à **Télécom Paris** (concours GEI-UNIV, 20 places par cette voie), licence à **Sorbonne Université** (**2e sur 57** en L2). **Quatre expériences data**, dont un modèle et un service mis en production chez DOCENT. Statistique, conception de métriques et modélisation bayésienne, jusqu'à la mise en production.

FORMATION

Cycle ingénieur Télécom Paris, Institut Polytechnique de Paris, Palaiseau — 2026 - 2029

Admis par le concours GEI-UNIV : 20 places à Télécom Paris par cette voie. 1re année : probabilités, analyse de Fourier, théorie de l'information.

Licence Informatique, mineure Mathématiques Sorbonne Université, Paris — 2023 - 2026

Moyennes : L1 **17.49** | L2 **15.92, 2e sur 57** | L3 **17.53** (sur 20). Sciences des données **1er sur 117** | Réseaux **1er sur 316** | Algorithmique II 3e sur 318 | Mathématiques 36e sur 2227.

EXPÉRIENCES PROFESSIONNELLES

DOCENT — Mars - Août 2026

Stagiaire Data Scientist

Plateforme d'analyse des tendances culturelles | équipe anglophone

- **Méthode de segmentation retenue en production**, choisie parmi 15 configurations évaluées sur 8 tests indépendants (scikit-learn, scipy, UMAP) ; score de recouvrement conçu sur mesure contre les partitions dégénérées qui remportaient les métriques standards.
- **Optimisation arrêtée sur preuve statistique :** le modèle s'accorde mieux avec les experts (ARI 0.189) que les experts entre eux (0.170). Piège UMAP identifié avant publication : silhouette de 0.018 à 0.326 à partition identique.
- **Moteur de rapprochement marque - artistes : 0.768** de précision au premier résultat contre 0.140 au hasard, 18 méthodes comparées sur trois protocoles ; variante bayésienne (Bernoulli-Beta).
- **Pipeline d'annotation par LLM :** trois workflows no-code (n8n) remplacés par un service Python en production (FastAPI, PostgreSQL, ~60 endpoints REST, Docker, AWS).

Agency 1301 — Automne 2025

Data Scientist (freelance)

Détection de republication non autorisée de photographies

- **Taux de détection rendu interprétable :** statuts d'échec typés ; une absence de résultat n'est plus confondue avec une panne technique. Base PostgreSQL ouverte aux équipes non techniques via NocoDB.

Prana France — Mai - Août 2025

Stagiaire Data Analyst

PME industrielle, ventilation

- Tableaux de bord Power BI (ventes, leads) sur données préparées en SQL ; assistant de support client par **RAG** en Python, déployé sur AWS.

SAS Datafoncier — Juin - Août 2024

Stagiaire Data Scientist

Start-up, analyse du marché immobilier

- Prédiction du marché immobilier par régression (validation croisée, réglage des hyperparamètres, données manquantes) ; features **ResNet** sur les photos pour estimer l'état des biens.

COMPÉTENCES TECHNIQUES

Statistique & ML: Tests d'hypothèses | bootstrap | inférence bayésienne | conception de métriques | scikit-learn | PyTorch | clustering | ACP, UMAP

IA générative: LLM | RAG | embeddings | bases vectorielles | n8n

Données & backend: Python | SQL | C/C++ | PostgreSQL | FastAPI | Pandas | Power BI | Docker | AWS (EC2, RDS, S3) | Git | Linux

Langues: Russe (maternelle) | Français (C1) | Anglais (B2, TOEFL iBT 87) | Permis B

Centres d'intérêt: Tennis | échecs | programmation compétitive | Kaggle